ALCALDIA DE SANTIAGO DE CALI

Equipo de Gobierno de Datos - CDO

# Geocodificacion del Registro Mercantil

Camara de Comercio - Proceso serverless en AWS (ITT)

Proyecto CaliTrack / ITT - 9 de octubre de 2026

Lambda aca-prod-geocodificador-camara-comercio-itt

# 1. Objetivo

Geocodificar masivamente las direcciones de los establecimientos del Registro Mercantil de la Camara de Comercio de Cali, con el fin de ubicarlos geograficamente y habilitar el analisis microterritorial de las unidades productivas de la ciudad. El proceso se implemento como una funcion serverless en AWS que consume la API oficial de geocodificacion de la Alcaldia, con un diseno reanudable por lotes y automatizado.

## 2. Fuente de datos

El insumo es el reporte general del Registro Mercantil, almacenado en el datalake del proyecto ITT. Es un archivo voluminoso con formato de exportacion de hoja de calculo.

| Parametro | Valor |
|---|---|
| Bucket S3 | aca-prod-calitrack-itt-datalake |
| Archivo | raw/camara_de_comercio/20260929-Reporte General Registro Mercantil.csv |
| Tamano / Filas | ~291 MB / ~561.000 registros |
| Formato | CSV separado por ';', codificacion latin-1 |
| Direccion a geocodificar | Columna direccion_12 (establecimiento) |
| Filtro aplicado | Solo Cali (nombre_11 = CALI) |
| Direcciones unicas (Cali) | 103.030 |

## 3. Arquitectura de la solucion

Se desarrollo la funcion AWS Lambda **aca-prod-geocodificador-camara-comercio-itt**, replicando el patron del geocodificador del RUD e integrando el normalizador de direcciones con la nomenclatura oficial de Cali. La API de geocodificacion limita cada solicitud a 18.000 registros, por lo que el trabajo se divide en lotes.

| Parametro | Valor |
|---|---|
| Funcion | aca-prod-geocodificador-camara-comercio-itt |
| Runtime / Memoria | Python 3.14 / 8.192 MB |
| Timeout / Almacenamiento | 900 s / 2.048 MB efimero |
| Layer | AWSSDKPandas-Python314:11 |
| Rol de ejecucion | aca-prod-damnificados-bronze-lambda-role |
| API de geocodificacion | https://geocodificador.ia.cali.gov.co/api |
| Tamano de lote | 12.000 direcciones (9 lotes) |
| Etiqueta | Proyecto: CaliTrack |

## 4. Flujo del proceso (reanudable)

Dado que la API tarda y una Lambda se detiene a los 15 minutos, el proceso se separa en fases que guardan su estado en S3 y pueden retomarse. Se invoca mediante el campo **action** del evento:

- **START:** lee el CSV, filtra Cali, normaliza y deduplica las direcciones, las divide en lotes y los envia al API. Guarda los identificadores de proceso en S3 y termina sin esperar.
- **CHECK:** consulta el avance de cada lote. Si aun no terminan, guarda el avance y finaliza. Cuando todos los lotes llegan al 100%, descarga los resultados, los une por direccion normalizada, asigna coordenadas a cada registro y publica el resultado final.

• **RECOVER:** permite registrar procesos de una ejecucion previa sin volver a geocodificar, como mecanismo de rescate.

• **Idempotencia:** si el archivo fuente no cambio (verificado por su huella ETag), se reutilizan los resultados y no se vuelve a consumir la API.

## 5. Productos generados

Los resultados se publican en curated/camara_de_comercio/{fecha}/ :

| Archivo | Contenido |
|---|---|
| camara_comercio_geocodificado.csv | Registros que SI obtuvieron coordenada (entregable principal) |
| camara_comercio_no_geocodificado.csv | Registros sin coordenada, con el motivo |
| resumen_geocodificacion.json | Metricas de la corrida |
| _jobs/ (carpeta) | Control interno del proceso (estado, lotes, marca de exito) |

## 6. Automatizacion del seguimiento

Para no depender de consultas manuales, se configuro una regla de Amazon EventBridge que invoca la verificacion (CHECK) automaticamente cada 5 minutos hasta que el proceso concluye.

| Parametro | Valor |
|---|---|
| Regla EventBridge | aca-prod-cc-itt-check-5min |
| Frecuencia | rate(5 minutes), ENABLED |
| Accion | Invocar la Lambda con {"action":"CHECK"} |
| Apagado al terminar | Manual, con perfil calitrack-aca (disable, no delete) |

El apagado de la regla se realiza manualmente al confirmar la finalizacion, porque el rol de ejecucion no cuenta con permiso para desactivar reglas y las politicas IAM no pueden modificarse desde el perfil de trabajo. Se emplea una operacion de desactivacion (disable), nunca de borrado.

## 7. Validacion y estado

• La lectura y normalizacion se validaron localmente sobre una muestra de 8.322 registros de Cali, con un 96% de direcciones aptas para geocodificar.

• Ejemplos de normalizacion: 'CR 108 44 75 AP 3 505' se estandariza a 'CR 108 # 44 - 75'; las direcciones rurales (por ejemplo 'VIA CALI - JAMUNDI KM 12') se marcan correctamente como no geocodificables.

• Corrida del 9 de octubre de 2026: 9 lotes, 103.030 direcciones unicas. El proceso avanzo de forma sostenida (3,6% -> 23,6% -> 47,9%) bajo seguimiento automatico.

## 8. Gobierno y seguridad

• Acceso mediante IAM Identity Center (SSO), sin llaves estaticas. Perfil de trabajo: calitrack-aca (cuenta 285757764705, region us-east-1).

• Todo recurso creado lleva la etiqueta Proyecto: CaliTrack y el prefijo aca-prod-.

• No se ejecutan operaciones de borrado en AWS desde la automatizacion; cualquier borrado lo realiza el responsable de forma explicita.

• El archivo fuente original en la zona raw/ no se modifica; los resultados se publican como archivos nuevos en la zona curated/.

Documento tecnico del Equipo de Gobierno de Datos (CDO), Alcaldia de Santiago de Cali. El detalle operativo y los comandos de referencia se encuentran en el archivo de contexto CONTEXTO_AWS_CAMARA_COMERCIO.md adjunto. Generado el 9 de octubre de 2026.